

Численные методы решения обыкновенных дифференциальных уравнений

Сравнительный анализ одношаговых методов и
физически-информированных нейронных сетей (PINN)

Мирасов Константин Владимирович

ИСУ 466716 · группа J3212 · вариант 13

Университет ИТМО · 09.06.2026

Эйлер

$$6.36 \times 10^{-2}$$

макс. ошибка

Хойн

$$3.04 \times 10^{-3}$$

макс. ошибка

РК4

$$2.38 \times 10^{-6}$$

макс. ошибка

PINN

$$\hat{\delta} = 0.256$$

истинное $\delta = 0.25$

Аннотация

В работе систематически исследованы численные методы решения задачи Коши для обыкновенных дифференциальных уравнений на примере задач варианта 13. Рассмотрены три классических явных одношаговых метода — Эйлера, Хойна и Рунге–Кутты четвёртого порядка (РК4); приведены их вывод, таблицы Бутчера и теория погрешности. На уравнении Бернулли $y' = -y/x - y^2$ выполнено сравнение методов с аналитическим решением: при $n = 20$ шагах максимальная абсолютная погрешность убывает от 6.4×10^{-2} (Эйлер) до 2.4×10^{-6} (РК4). Эмпирический анализ порядка сходимости в логарифмических координатах подтверждает теоретические порядки: наблюдаемые показатели составили $\hat{p} \approx 1.05, 2.03$ и 3.89 . В качестве моста к современным методам машинного обучения рассмотрена физически-информированная нейронная сеть (PINN) на затухающем осцилляторе: в прямой задаче достигнута точность $\approx 2.3 \times 10^{-3}$, а в обратной задаче по зашумлённым данным восстановлен коэффициент затухания $\hat{\delta} \approx 0.256$ при истинном $\delta = 0.25$. Проведено сопоставление классического и нейросетевого подходов по точности, вычислительной стоимости и применимости к обратным задачам.

Ключевые слова: задача Коши, метод Эйлера, метод Хойна, метод Рунге–Кутты, порядок сходимости, абсолютная устойчивость, жёсткость, PINN, автоматическое дифференцирование, обратная задача.

Основные результаты

Подтверждены порядки $\hat{p} = 1.046, 2.034, 3.890$; РК4 на осцилляторе даёт ошибку 3.06×10^{-8} , а PINN решает обратную задачу идентификации δ по зашумлённым данным.

Воспроизводимость

Все рисунки, таблицы и численные значения получены скриптами `reports/scripts/` из данных `reports/data/` при фиксированном `SEED = 13`. Репозиторий: [mezgou/itmo-differential-equations-course](https://mezgou.itmo-differential-equations-course).

Содержание

1 Введение	3
2 Теоретическая часть	3
2.1 Задача Коши и корректность	3
2.2 Одношаговые методы и семейство Рунге–Кутты	4
2.3 Погрешность и сходимость	6
2.4 Устойчивость и жёсткость	7
2.5 Сведение уравнения высшего порядка к системе первого порядка	8
2.6 Физически-информированные нейронные сети (PINN)	8
2.7 Сравнение классических методов и PINN	9
3 Практическая часть: численные эксперименты	9
3.1 Постановка задачи первого порядка	10
3.2 Сравнение методов на фиксированной сетке	10
3.3 Погрешности методов	10
3.4 Анализ порядка сходимости	11
3.5 Иллюстрация областей устойчивости	12
4 Применение и современные методы (PINN)	13
4.1 Осциллятор как система: решение методом РК4	13
4.2 Прямая задача PINN	14
4.3 Обратная задача PINN: идентификация параметра	15
4.4 Сопоставление классического и нейросетевого подходов	15
5 Обсуждение	16
6 Заключение	16
Приложение. Реализация одношаговых методов	17
Список литературы	18

1 Введение

Обыкновенные дифференциальные уравнения (ОДУ) служат базовым языком описания динамических процессов в физике, технике, биологии и экономике. Центральной постановкой является *задача Коши*: найти функцию, удовлетворяющую дифференциальному уравнению и заданному начальному условию. Лишь для узкого класса уравнений решение выражается в элементарных функциях, поэтому на практике доминируют *численные* методы, дающие приближённое решение на дискретной сетке узлов [1], [2]. Качество такого приближения определяется порядком точности метода и его устойчивостью, а адекватность — согласием с аналитическим эталоном там, где он доступен.

Настоящая работа преследует двойную цель. Во-первых, на конкретных задачах варианта 13 строго излагаются и сопоставляются три классических явных одношаговых метода — Эйлера, Хойна (улучшенный Эйлер) и Рунге–Кутты четвёртого порядка (РК4): приводится их вывод, теория локальной и глобальной погрешности, понятие абсолютной устойчивости, а экспериментально измеряется *наблюдаемый порядок сходимости*. Во-вторых, в качестве моста к современным методам исследуется физически-информированная нейронная сеть (PINN) [3] как альтернативный, основанный на машинном обучении способ решения ОДУ; на одной и той же задаче о затухающем осцилляторе проводится прямое сравнение РК4 и PINN, включая недоступную классическим сеточным методам *обратную задачу* идентификации параметра. Связующим техническим приёмом выступает сведение уравнения высшего порядка к системе уравнений первого порядка.

Вклад работы состоит в следующем: (i) дано замкнутое изложение теории одношаговых методов с таблицами Бутчера, оценками погрешности и областями устойчивости; (ii) проведён вычислительный эксперимент, подтверждающий теоретические порядки $p = 1, 2, 4$ методом линейной регрессии в логарифмических координатах; (iii) реализована и обучена PINN для прямой и обратной задач, а результаты сопоставлены с классическим РК4 в единой таблице. Дальнейшее изложение построено так: в разделе 2 приводится теоретическая часть; в разделе 3 — численные эксперименты на ОДУ первого порядка; в разделе 4 — применение к осциллятору и сравнение классики с PINN; разделы 5 и 6 содержат обсуждение и заключение.

2 Теоретическая часть

В настоящем разделе изложены математические основы численного интегрирования обыкновенных дифференциальных уравнений (ОДУ): постановка задачи Коши и условия её корректности, общая конструкция явных одношаговых методов и семейства Рунге–Кутты, теория погрешности и сходимости, понятие абсолютной устойчивости, приём сведения уравнения высшего порядка к системе первого порядка, а также современный подход на основе физически-информированных нейронных сетей (PINN). Изложение опирается на классические монографии [1], [4], [5], [6] и работу [3]. Все методы иллюстрируются на задачах варианта 13.

2.1 Задача Коши и корректность

Рассматривается начальная задача (задача Коши) для скалярного ОДУ первого порядка

$$y'(x) = f(x, y(x)), \quad y(x_0) = y_0, \quad x \in [x_0, X], \quad (1)$$

где $f : D \rightarrow \mathbb{R}$ задана на области $D \subseteq \mathbb{R}^2$, содержащей начальную точку (x_0, y_0) . Под решением задачи (1) понимается непрерывно дифференцируемая функция $y : [x_0, X] \rightarrow \mathbb{R}$, удовлетворяющая уравнению и начальному условию.

Прежде чем строить приближённое решение, необходимо убедиться, что точное решение существует и единственно: только тогда численное приближение имеет содержательный смысл. Достаточные условия даёт классическая теорема Пикара–Линделёфа, ключевую роль в которой играет следующее условие.

Определение (условие Липшица): Функция $f(x, y)$ удовлетворяет условию Липшица по переменной y на множестве D , если существует постоянная $L \geq 0$ (постоянная Липшица) такая, что

$$|f(x, y_1) - f(x, y_2)| \leq L|y_1 - y_2| \quad \text{для всех } (x, y_1), (x, y_2) \in D. \quad (2)$$

Условие (2) ограничивает скорость изменения правой части по y и тем самым исключает «разбегание» близких решений. На практике его достаточно проверять локально: если f непрерывна и имеет ограниченную частную производную $\partial f / \partial y$ на выпуклой области, то по теореме о среднем условии Липшица выполнено с $L = \sup |\partial f / \partial y|$.

Теорема (Пикар–Линделёф): Пусть f непрерывна в прямоугольнике $R = \{(x, y) : |x - x_0| \leq a, |y - y_0| \leq b\}$ и удовлетворяет на нём условию Липшица (2) по y . Тогда на отрезке $|x - x_0| \leq h_*$, где $h_* = \min(a, b/M)$ и $M = \max_R |f(x, y)|$, задача Коши (1) имеет единственное решение $y(x)$.

Доказательство опирается на сведение (1) к эквивалентному интегральному уравнению $y(x) = y_0 + \int_{x_0}^x f(t, y(t)) dt$ и применение принципа сжимающих отображений к оператору Пикара; условие Липшица обеспечивает сжатие, а последовательные приближения сходятся к решению равномерно [1], [4].

Для задачи варианта 13

$$y' = -\frac{y}{x} - y^2, \quad y(1) = 2, \quad x \in [1, 2], \quad (3)$$

правая часть $f(x, y) = -y/x - y^2$ и её производная $\partial f / \partial y = -1/x - 2y$ непрерывны в окрестности начальной точки, поэтому условия теоремы выполнены и решение существует и единственно. Это уравнение Бернулли; подстановка $u = 1/y$ сводит его к линейному, что даёт точное решение

$$\varphi(x) = \frac{1}{x(\ln x + \frac{1}{2})}, \quad (4)$$

используемое далее как эталон при оценке погрешности.

2.2 Одношаговые методы и семейство Рунге–Кутты

Численное интегрирование заменяет непрерывную задачу (1) дискретной: на равномерной сетке $x_k = x_0 + kh$, $k = 0, 1, \dots, n$, с шагом $h = (X - x_0)/n$ ищутся приближения $y_k \approx y(x_k)$. Метод называется **одношаговым**, если значение y_{k+1} вычисляется только по предыдущему значению y_k (в отличие от многошаговых методов, использующих несколько предыдущих узлов).

Определение (одношаговый метод): Одношаговым методом для задачи (1) называется рекуррентная схема

$$y_{k+1} = y_k + h \cdot \Phi(x_k, y_k, h), \quad k = 0, 1, \dots, n-1, \quad (5)$$

где Φ – функция приращения метода. Метод **явный**, если Φ выражается только через уже известные величины; в противном случае метод **неявный**.

Различные методы отличаются выбором функции приращения Φ , аппроксимирующей осреднённый наклон решения на шаге $[x_k, x_{k+1}]$. Наиболее гибкий способ построить Φ высокого порядка точности даёт семейство методов Рунге–Кутты, в котором наклон оценивается как взвешенная комбинация значений правой части в нескольких промежуточных точках (стадиях).

Определение (метод Рунге–Кутты): s -стадийным методом Рунге–Кутты называется одношаговый метод вида

$$y_{k+1} = y_k + h \sum_{i=1}^s b_i k_i, \quad k_i = f\left(x_k + c_i h, y_k + h \sum_{j=1}^s a_{ij} k_j\right), \quad (6)$$

где числа a_{ij} , b_i , c_i ($i, j = 1, \dots, s$) – коэффициенты метода.

Коэффициенты удобно записывать в виде **таблицы Бутчера**

$$\left(\begin{array}{c|c} \mathbf{c} & \mathbf{A} \\ \hline & \mathbf{b}^\top \end{array} \right), \quad \mathbf{A} = (a_{ij}), \quad \mathbf{b} = (b_i), \quad \mathbf{c} = (c_i), \quad (7)$$

где матрица $\mathbf{A}$ задаёт стадии, вектор $\mathbf{b}$ – веса, вектор $\mathbf{c}$ – узлы. Метод явный тогда и только тогда, когда $\mathbf{A}$ строго нижнетреугольна ($a_{ij} = 0$ при $j \geq i$): в этом случае каждая стадия k_i зависит лишь от уже вычисленных $k_1, \dots, k_{i-1}$. Обычно требуют согласование узлов $c_i = \sum_j a_{ij}$, что обеспечивает точное интегрирование на автономных задачах. Ниже выводятся три явных метода, используемых в работе.

2.2.1 Явный метод Эйлера

Простейший метод получается из разложения точного решения в ряд Тейлора в окрестности узла x_k :

$$y(x_{k+1}) = y(x_k) + h y'(x_k) + \frac{h^2}{2} y''(\xi_k), \quad \xi_k \in (x_k, x_{k+1}). \quad (8)$$

Подставляя $y'(x_k) = f(x_k, y(x_k))$ из уравнения (1) и отбрасывая остаточный член $O(h^2)$, приходим к **явному методу Эйлера**

$$y_{k+1} = y_k + h f(x_k, y_k). \quad (9)$$

Геометрически это шаг по касательной к интегральной кривой, проведённой в точке (x_k, y_k) . Метод (9) соответствует функции приращения $\Phi = f(x_k, y_k)$ и одностадийной таблице Бутчера

$$\left(\begin{array}{c|c} 0 & 0 \\ \hline & 1 \end{array} \right). \quad (10)$$

2.2.2 Метод Хойна (улучшенный Эйлер, РК2)

Точность метода Эйлера ограничена тем, что наклон вычисляется лишь в начале шага. Метод Хойна (предиктор–корректор, явная трапеция) усредняет наклоны в начале и в конце шага. Сначала **предиктор** – пробный шаг Эйлера – даёт грубую оценку $\tilde{y}_{k+1} = y_k + h f(x_k, y_k)$, после чего **корректор** усредняет наклоны:

$$y_{k+1} = y_k + \frac{h}{2} (f(x_k, y_k) + f(x_{k+1}, \tilde{y}_{k+1})). \quad (11)$$

Это есть явная аппроксимация интегральной формы $y(x_{k+1}) = y(x_k) + \int_{x_k}^{x_{k+1}} f dx$ квадратурой трапеций. В обозначениях (6) метод двухстадийный с $k_1 = f(x_k, y_k)$, $k_2 = f(x_k + h, y_k + h k_1)$ и весами $b_1 = b_2 = 1/2$; его таблица Бутчера

$$\left(\begin{array}{c|cc} 0 & 0 & 0 \\ \hline 1 & 1 & 0 \\ \hline \frac{1}{2} & \frac{1}{2} & \frac{1}{2} \end{array} \right). \quad (12)$$

2.2.3 Классический метод Рунге–Кутты четвёртого порядка (РК4)

Наиболее употребительный явный метод – классический четырёхстадийный РК4. Он вычисляет четыре оценки наклона:

$$\begin{aligned}
k_1 &= f(x_k, y_k), & k_2 &= f\left(x_k + \frac{h}{2}, y_k + \frac{h}{2}k_1\right), \\
k_3 &= f\left(x_k + \frac{h}{2}, y_k + \frac{h}{2}k_2\right), & k_4 &= f(x_k + h, y_k + hk_3),
\end{aligned} \tag{13}$$

и комбинирует их с весами Симпсона $(1, 2, 2, 1)/6$:

$$y_{k+1} = y_k + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4). \tag{14}$$

Узлы $\mathbf{c} = (0, 1/2, 1/2, 1)$ и веса $\mathbf{b} = (1/6, 1/3, 1/3, 1/6)$ подобраны так, чтобы погасить члены ряда Тейлора вплоть до h^4 включительно. Таблица Бутчера метода РК4

$$\left(\begin{array}{c|cccc} 0 & 0 & 0 & 0 & 0 \\ \frac{1}{2} & \frac{1}{2} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{2} & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ \hline & \frac{1}{6} & \frac{1}{3} & \frac{1}{3} & \frac{1}{6} \end{array} \right). \tag{15}$$

2.3 Погрешность и сходимость

Качество одношагового метода характеризуется двумя величинами: локальной погрешностью на одном шаге и накопленной (глобальной) погрешностью на всём отрезке.

Определение (локальная погрешность усечения): Локальной погрешностью усечения (LTE) метода (5) называется невязка, возникающая при подстановке **точного** решения в одношаговую формулу:

$$\tau_k = y(x_{k+1}) - y(x_k) - h \cdot \Phi(x_k, y(x_k), h). \tag{16}$$

Метод имеет **порядок точности** p , если $\tau_k = O(h^{p+1})$ равномерно по k .

Для метода Эйлера сравнение (8) и (9) сразу даёт $\tau_k = (h^2/2)y''(\xi_k) = O(h^2)$, то есть порядок $p = 1$. Аналогичное разложение по Тейлору для метода Хойна показывает $\tau_k = O(h^3)$ ($p = 2$), а для РК4 – $\tau_k = O(h^5)$ ($p = 4$); проверка последнего требует сопоставления тейлоровских разложений приближённого и точного решений до членов порядка h^4 [4], [5].

Определение (глобальная погрешность): Глобальной погрешностью в узле x_k называется отклонение приближения от точного решения

$$e_k = y(x_k) - y_k. \tag{17}$$

Метод **согласован** (consistent), если $\tau_k/h \rightarrow 0$ при $h \rightarrow 0$ (то есть порядок $p \geq 1$), и **сходится**, если $\max_k |e_k| \rightarrow 0$ при $h \rightarrow 0$. Связь локальной и глобальной погрешности устанавливает следующая теорема, являющаяся для одношаговых методов аналогом принципа «согласованность + устойчивость $\Rightarrow$ сходимость».

Теорема (о порядке и глобальной погрешности): Пусть правая часть f удовлетворяет условию Липшица (2) с постоянной L , а одношаговый метод (5) имеет локальную погрешность порядка $p + 1$, то есть $|\tau_k| \leq Ch^{p+1}$. Тогда глобальная погрешность оценивается как

$$\max_{0 \leq k \leq n} |e_k| \leq \frac{Ch^p}{L} (e^{L(X-x_0)} - 1) = O(h^p), \tag{18}$$

то есть метод сходится с порядком p .

Идея доказательства: из определений (16), (17) и условия Липшица получают рекуррентное неравенство $|e_{k+1}| \leq (1 + hL)|e_k| + Ch^{p+1}$; его разрешение через дискретную лемму Гронуолла и оценка $(1 + hL)^k \leq e^{L(X-x_0)}$ дают (18). Содержательно: на отрезке укладывается $n = (X - x_0)/h$ шагов, поэтому при суммировании локальных погрешностей порядка h^{p+1} теряется один порядок по h , и глобальная погрешность оказывается порядка h^p [1], [6]. Таким образом, рассмотренные методы сходятся с порядками $p = 1$ (Эйлер), $p = 2$ (Хойн) и $p = 4$ (РК4); это подтверждается экспериментальным измерением скорости убывания погрешности при дроблении шага.

2.4 Устойчивость и жёсткость

Малость локальной погрешности гарантирует сходимость лишь при $h \rightarrow 0$, но не объясняет поведения метода при **фиксированном** шаге, когда накопленные ошибки могут неограниченно нарастать. Это поведение изучают на скалярном **тестовом уравнении** Далквиста

$$y' = \lambda y, \quad \lambda \in \mathbb{C}, \quad \operatorname{Re} \lambda \leq 0, \quad (19)$$

точное решение которого $y(x) = y_0 e^{\lambda x}$ при $\operatorname{Re} \lambda \leq 0$ не возрастает. Применение любого одношагового метода к (19) даёт геометрическую прогрессию

$$y_{k+1} = R(z)y_k, \quad z = h\lambda, \quad (20)$$

где $R(z)$ – **функция устойчивости** метода, а $z = h\lambda$ – безразмерный комплексный параметр шага. Для явных методов $R(z)$ совпадает с отрезком ряда e^z , аппроксимирующим точный множитель перехода $e^{h\lambda}$:

$$\begin{aligned} R_{\text{Эйлер}}(z) &= 1 + z, \\ R_{\text{РК2}}(z) &= 1 + z + \frac{z^2}{2}, \\ R_{\text{РК4}}(z) &= 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \frac{z^4}{24}. \end{aligned} \quad (21)$$

Численное решение не нарастает тогда и только тогда, когда $|R(z)| \leq 1$.

Определение (область абсолютной устойчивости): Областью абсолютной устойчивости одношагового метода называется множество

$$S = \{z \in \mathbb{C} : |R(z)| \leq 1\} \quad (22)$$

значений $z = h\lambda$, при которых численное решение тестового уравнения (19) остаётся ограниченным.

У всех явных методов область S **ограничена**: например, для метода Эйлера это круг $|1 + z| \leq 1$ радиуса 1 с центром в -1 , для РК4 – более крупная область, простирающаяся по вещественной оси примерно до $z \approx -2.79$. Поэтому при $\operatorname{Re} \lambda < 0$ для устойчивости требуется ограничение на шаг $h \leq h_{\max}(\lambda)$. Когда задача содержит компоненты с сильно различающимися по модулю собственными значениями λ (масштабами времени), это ограничение становится критическим.

Определение (жёсткая задача): Задача Коши называется **жёсткой** (stiff), если устойчивость явного метода вынуждает выбирать шаг h существенно меньшим, чем того требует желаемая точность, – из-за наличия быстро затухающих компонент с большими $|\operatorname{Re} \lambda|$.

Для жёстких задач предпочтительны **неявные** методы, обладающие неограниченной областью устойчивости.

Определение (А-устойчивость): Метод называется **А-устойчивым**, если его область абсолютной устойчивости содержит всю левую полуплоскость: $S \supseteq \{z \in \mathbb{C} : \operatorname{Re} z \leq 0\}$.

А-устойчивость снимает ограничение на шаг по соображениям устойчивости и потому особенно ценна для жёстких задач. Однако явные методы Рунге–Кутты А-устойчивыми быть не могут: соответствующая $R(z)$ – многочлен и неизбежно неограниченно растёт при $|z| \rightarrow \infty$. Более того, согласно **второму барьеру Далквиста**, среди линейных многошаговых методов А-устойчивые имеют порядок не выше второго; повышение порядка при сохранении А-устойчивости требует одношаговых неявных схем (например, неявных методов Рунге–Кутты или Гаусса) [4], [6]. Задачи варианта 13 нежёсткие, поэтому рассмотренных явных методов с умеренным шагом достаточно.

2.5 Сведение уравнения высшего порядка к системе первого порядка

Изложенные методы сформулированы для уравнения первого порядка, однако они без изменений переносятся на уравнения высшего порядка благодаря стандартному приёму сведения к системе. Пусть дано уравнение n -го порядка, разрешённое относительно старшей производной:

$$y^{(n)} = g(x, y, y', \dots, y^{(n-1)}), \quad y^{(i)}(x_0) = y_0^{(i)}, \quad i = 0, \dots, n-1. \quad (23)$$

Введём вектор неизвестных из самой функции и её производных $u_i = y^{(i-1)}$, $i = 1, \dots, n$. Тогда $u_{i'} = y^{(i)} = u_{i+1}$ при $i < n$, а $u_{n'} = y^{(n)}$ выражается через g , и (23) превращается в автономную по форме систему первого порядка

$$u' = F(x, u), \quad F = \begin{pmatrix} u_2 \\ u_3 \\ \vdots \\ g(x, u_1, \dots, u_n) \end{pmatrix}, \quad u(x_0) = u_0. \quad (24)$$

Все одношаговые методы (5)–(14) применяются к системе (24) **покомпонентно**: величины y_k и стадии k_i становятся векторами, а правая часть f заменяется на F , тогда как структура формул (коэффициенты A , b , c) сохраняется.

Проиллюстрируем это на уравнении второго порядка варианта 13

$$yy'' = (y')^2(y^2y' + 1), \quad y(0) = 1, \quad y'(0) = -3. \quad (25)$$

Полагая $u_1 = y$, $u_2 = y'$, получаем

$$\left\{ u_{1'} = u_2, u_{2'} = \frac{u_2^2(u_1^2u_2 + 1)}{u_1}, \quad u_1(0) = 1, \quad u_2(0) = -3, \right. \quad (26)$$

после чего система (26) интегрируется векторным методом РК4.

2.6 Физически-информированные нейронные сети (PINN)

Альтернативу сеточным методам предоставляет современный подход на основе **физически-информированных нейронных сетей** (Physics-Informed Neural Networks, PINN), предложенный в [3]. Его идея состоит в том, чтобы искать решение не в виде таблицы значений на сетке, а в виде **непрерывной** параметрической функции – нейронной сети $f_\theta(x) \approx y(x)$ с вектором обучаемых параметров θ (веса и смещения). Используется полносвязная сеть умеренного размера (порядка 3–5 слоёв по 32–64 нейрона) с гладкой функцией активации $\tanh$, что гарантирует дифференцируемость f_θ по входу x .

Ключевое преимущество такого представления: производные $f_{\theta'}(x)$, $f_{\theta''}(x)$ вычисляются **точно** средствами автоматического дифференцирования (autograd) по графу вычислений сети, без конечно-разностной аппроксимации и без введения сетки. Это позволяет напрямую подставлять сеть и её производные в дифференциальное уравнение. Соответствие уравнению и начальным условиям достигается минимизацией **физически-информированного функционала потерь**. Для затухающего осциллятора варианта 13

$$x'' + 2\delta x' + \omega_0^2 x = 0, \quad x(0) = 0, \quad x'(0) = 1.5, \quad (27)$$

функция потерь складывается из штрафов за нарушение начальных условий и невязки уравнения, осреднённой по набору коллокационных точек $\{t_i\}_{i=1}^N$:

$$L(\theta) = \lambda_0 f_\theta(0)^2 + \lambda_1 (f'_\theta(0) - 1.5)^2 + \frac{1}{N} \sum_{i=1}^N (f''_\theta(t_i) + 2\delta f'_\theta(t_i) + \omega_0^2 f_\theta(t_i))^2, \quad (28)$$

где $\lambda_0, \lambda_1 > 0$ – весовые коэффициенты. Минимизация $L(\theta)$ методом Adam обучает сеть удовлетворять уравнению; коллокационные точки t_i играют роль, аналогичную узлам сетки, но не требуют упорядоченности и шага.

Отдельное достоинство PINN – естественное решение **обратных задач**, в которых неизвестен один из физических параметров уравнения. Если коэффициент затухания δ подлежит определению по результатам измерений, его объявляют ещё одним **обучаемым параметром** и оптимизируют совместно с θ , добавляя к (28) штраф за отклонение от зашумлённых данных $\{(t_j, y_j)\}_{j=1}^M$:

$$L_{\text{data}}(\theta, \delta) = L(\theta, \delta) + \frac{\lambda}{M} \sum_{j=1}^M (f_\theta(t_j) - y_j)^2. \quad (29)$$

Совместная минимизация по (θ, δ) восстанавливает истинное значение параметра ($\hat{\delta} \rightarrow 0.25$ для варианта 13). Классические сеточные методы такой возможности напрямую не дают: оценка параметров требует отдельной внешней процедуры оптимизации.

2.7 Сравнение классических методов и PINN

Классические одношаговые методы и PINN решают одну и ту же задачу принципиально разными средствами; их сильные и слабые стороны систематизированы в таблице ниже.

Аспект	Классические методы	PINN
Представление решения	дискретное (на сетке)	непрерывное, дифференцируемое $f_\theta(x)$
Производные	неявно, через приращения на шаге	автоматическое дифференцирование
Сходимость	детерминированный порядок $O(h^p)$	стохастическая оптимизация, порядок не гарантирован
Вычислительная стоимость	очень низкая, прямой проход	высокая: итеративное обучение
Гарантии погрешности	строгие априорные оценки	эмпирические, без строгих границ
Обратные задачи	требуют отдельной процедуры	естественно: обучаемый параметр
Жёсткость / сложные области	ограничение на шаг h	гибко, но чувствительно к гиперпараметрам

Таблица 1. Сравнение классических одношаговых методов и PINN.

Таким образом, классические методы Рунге–Кутты остаются золотым стандартом для прямых нежёстких задач, обеспечивая высокую точность, низкую стоимость и строгие гарантии погрешности, тогда как PINN представляет собой гибкий подход машинного обучения, особенно ценный в обратных задачах и в ситуациях, где построение сетки затруднительно, – ценой высокой стоимости обучения и отсутствия строгих теоретических гарантий.

3 Практическая часть: численные эксперименты

В данном разделе теоретические выводы проверяются вычислительно. Все приближения сопоставляются с аналитическим решением, а рисунки и числовые данные получены скриптами на Python (`numpy`, `matplotlib`, `pandas`) при фиксированном начальном значении генератора `SEED = 13`; исходные коды и таблицы данных приложены к работе.

3.1 Постановка задачи первого порядка

Рассматривается задача Коши варианта 13 (3): $y' = -y/x - y^2$ с начальным условием $y(1) = 2$ на отрезке $x \in [1, 2]$. Как показано в (4), её точное решение есть $\varphi(x) = 1/(x(\ln x + 1/2))$ с контрольным значением $\varphi(2) \approx 0.41906$. Интегрирование проводится на равномерной сетке из $n = 20$ шагов с шагом $h = (2 - 1)/20 = 0.05$.

3.2 Сравнение методов на фиксированной сетке

На рис. 1 показаны аналитическое решение и три приближения. Визуально кривые Хойна и РК4 неотличимы от точного решения, тогда как метод Эйлера систематически занижает значения, накапливая погрешность вдоль отрезка. Соответствующие числовые значения в части узлов приведены в табл. 2.




Рис. 1. Точное решение $\varphi(x)$ и приближения методами Эйлера, Хойна и РК4 для задачи варианта 13 на $[1, 2]$ при $n = 20$.

x	Точное φ	Эйлер	Хойн	РК4
1.0	2.000000	2.000000	2.000000	2.000000
1.1	1.527088	1.474548	1.529760	1.527090
1.2	1.221321	1.157993	1.224356	1.221323
1.3	1.009007	0.946627	1.011835	1.009009
1.4	0.853926	0.795914	0.856427	0.853928
1.5	0.736270	0.683371	0.738449	0.736271
1.6	0.644327	0.596382	0.646224	0.644329
1.7	0.570754	0.527315	0.572411	0.570755
1.8	0.510721	0.471281	0.512176	0.510722
1.9	0.460931	0.425007	0.462218	0.460932
2.0	0.419060	0.386219	0.420205	0.419060

Таблица 2. Значения точного и приближённых решений в части узлов сетки (каждый второй узел).

3.3 Погрешности методов

Для каждого метода вычислены максимальная абсолютная $\Delta_l = \max_{1 \leq k \leq n} |\varphi(x_k) - \tilde{y}_k^l|$ и максимальная относительная $\delta_l = \max_{1 \leq k \leq n} |\varphi(x_k) - \tilde{y}_k^l| / |\tilde{y}_k^l|$ погрешности; в относительной метрике знаменателем служит численное приближение, как в исходном скрипте (начальный узел исключён, см. (17)). Результаты собраны в табл. 3. Переход от Эйлера к Хойну уменьшает абсолютную

погрешность примерно в 21 раз, а от Хойна к РК4 — ещё на три порядка, что согласуется с ростом порядка точности методов. Поточечное распределение абсолютной погрешности вдоль отрезка показано на рис. 2 в логарифмическом масштабе: кривая РК4 лежит на несколько порядков ниже остальных, тогда как погрешность метода Эйлера наибольшая практически во всех узлах.




Рис. 2. Поточечная абсолютная погрешность $|\varphi(x_k) - \tilde{y}_k|$ методов вдоль отрезка $[1, 2]$; начальный узел с нулевой ошибкой исключён (логарифмическая ось ординат).

Метод	Абс. погрешность Δ_l	Отн. погрешность δ_l
Эйлер ($p = 1$)	6.359×10^{-2}	8.503×10^{-2}
Хойн ($p = 2$)	3.035×10^{-3}	2.951×10^{-3}
РК4 ($p = 4$)	2.376×10^{-6}	1.904×10^{-6}

Таблица 3. Максимальные абсолютная и относительная погрешности методов при $n = 20$.

3.4 Анализ порядка сходимости

Главный вычислительный результат работы — эмпирическая проверка порядка сходимости. Задача решалась последовательно на сетках с $n \in \{10, 20, 40, 80, 160, 320, 640\}$ ($h = 1/n$), и для каждого метода строилась зависимость максимальной погрешности от шага h в логарифмических координатах (рис. 3). В силу оценки (18) $\log \Delta \approx p \log h + \text{const}$, поэтому наблюдаемый порядок $\hat{p}$ оценивался как наклон прямой линейной регрессии $\log \Delta$ по $\log h$. Полученные значения (табл. 4) близки к теоретическим $p = 1, 2, 4$. Для РК4 наклон оценивался по сеткам $n \leq 160$: при дальнейшем дроблении погрешность выходит на «полку» машинной точности (около 2.4×10^{-12} при $n = 640$), где ошибка округления начинает доминировать над ошибкой усечения, и измеренный наклон занижается.




Рис. 3. Зависимость максимальной абсолютной погрешности от шага h (log-log). Пунктиром показаны опорные наклоны 1, 2, 4; в подписях — оценённые наблюдаемые порядки $\hat{p}$; fit для РК4 выполнен по сеткам $n \leq 160$.

Метод	Теоретический p	Наблюдаемый $\hat{p}$
Эйлер	1	1.046
Хойн	2	2.034
РК4	4	3.890

Таблица 4. Теоретический и наблюдаемый (по регрессии) порядки сходимости.

3.5 Иллюстрация областей устойчивости

Для наглядного подтверждения теории устойчивости (21) и (22) на рис. 4 построены границы областей абсолютной устойчивости трёх методов в плоскости $z = h\lambda$. Область метода Эйлера — круг радиуса 1 с центром в точке -1 ; область РК2 несколько шире, а область РК4 — наибольшая, простираясь по вещественной оси примерно до $z \approx -2.79$. Все области ограничены, что отражает условный характер устойчивости явных методов. Поскольку задачи варианта 13 не являются жёсткими, ограничение на шаг по устойчивости не вступает в конфликт с требуемой точностью, и явных методов с умеренным шагом достаточно.




Рис. 4. Области абсолютной устойчивости $\{z : |R(z)| \leq 1\}$ методов Эйлера, Хойна (PK2) и РК4 в комплексной плоскости $z = h\lambda$.

4 Применение и современные методы (PINN)

В этом разделе классический и нейросетевой подходы применяются к одной и той же физической задаче — затухающему гармоническому осциллятору варианта 13 (27) $x'' + 2\delta x' + \omega_0^2 x = 0$ с $\delta = 0.25$, $\omega_0 = 1.8$, $x(0) = 0$, $x'(0) = 1.5$ на отрезке $t \in [0, 12]$. Его точное решение — слабозатухающие колебания $x(t) = (1.5/\omega)e^{-\delta t} \sin(\omega t)$ с частотой $\omega = \sqrt{\omega_0^2 - \delta^2} \approx 1.78255$.

4.1 Осциллятор как система: решение методом РК4

Применяя приём (24), сведём уравнение второго порядка к системе первого порядка с состоянием $\mathbf{u} = (x, x')^\top$:

$$u_1' = u_2, \quad u_2' = -2\delta u_2 - \omega_0^2 u_1, \quad u_1(0) = 0, \quad u_2(0) = 1.5, \quad (30)$$

и проинтегрируем её векторным методом РК4. Как видно на рис. 5, численное решение практически совпадает с аналитическим: максимальная абсолютная погрешность на $[0, 12]$ составляет лишь 3.06×10^{-8} . Это демонстрирует, что для прямой нежёсткой задачи классический РК4 обеспечивает фактически эталонную точность при ничтожной вычислительной стоимости.




Рис. 5. Затухающий осциллятор: решение методом RK4 (через сведение к системе) в сравнении с точным $x(t)$ на $[0, 12]$.

4.2 Прямая задача PINN

Решение того же осциллятора аппроксимировалось физически-информированной нейронной сетью (28). Использована полносвязная сеть из четырёх скрытых слоёв по 64 нейрона с активацией $\tanh$; вход t нормирован в $[-1, 1]$, выход — приближение $x(t)$. Производные вычислялись автоматическим дифференцированием, а функция потерь складывалась из штрафов за начальные условия ($\lambda_0 = \lambda_1 = 100$) и невязки уравнения на 400 коллокационных точках. Обучение проводилось оптимизатором Adam (скорость 10^{-3} , 20000 эпох) с последующей доводкой L-BFGS; для ускорения сходимости применялась короткая инициализация по аналитическому решению. Такая warm-start инициализация трактуется как вычислительный приём стабилизации обучения на длинном временном интервале, а не как полностью unsupervised-режим PINN; этот момент учитывается в обсуждении. Сводка гиперпараметров приведена в табл. 5. На рис. 6 приближение PINN визуально совпадает с точным решением: максимальная абсолютная погрешность на плотной сетке равна 2.3×10^{-3} . Кривая обучения (рис. 7) показывает монотонное убывание физической невязки и удержание начальных условий весовыми штрафами.

Архитектура	Коллокация	Оптимизация	Режим
$4 \times 64, \tanh$	$N_f = 400$	Adam 20000 эпох + L-BFGS 500 ит.	warm-start, SEED = 13

Таблица 5. Ключевые гиперпараметры прямой PINN-модели для осциллятора.




Рис. 6. Прямая задача: PINN и точное решение $x(t)$.




Рис. 7. Кривая обучения PINN (логарифмический масштаб).

4.3 Обратная задача PINN: идентификация параметра

Принципиальное преимущество PINN раскрывается в обратной задаче. По зашумлённым наблюдениям $y_j = x(t_j) + \varepsilon_j$, $\varepsilon_j \sim \mathcal{N}(0, 0.05^2)$ ($M = 100$ точек), требуется восстановить неизвестный коэффициент затухания δ . Согласно (29), δ объявляется обучаемым параметром (через softplus для положительности, со стартовым значением $\delta_0 = 1.0$) и оптимизируется совместно с весами сети. На рис. 8 показаны зашумлённые данные с восстановленной кривой и сходимость оценки $\hat{\delta}$ к истинному значению. Итоговая оценка $\hat{\delta} \approx 0.256$ (абсолютная ошибка 6.1×10^{-3} , относительная 2.5%) близка к истинному $\delta = 0.25$, несмотря на уровень шума; численная сводка дана в табл. 6. Классические сеточные методы такой идентификации напрямую не дают.

Параметр	Истина	Старт	Оценка	Ошибка
δ	0.25	1.00	0.256141	6.14×10^{-3} (2.46%)

Таблица 6. Результат обратной задачи PINN при $M = 100$ наблюдениях с шумом $\mathcal{N}(0, 0.05^2)$ и SEED = 13.




Рис. 8. Обратная задача: (слева) зашумлённые данные, точное решение и восстановление PINN; (справа) сходимость оценки $\hat{\delta}$ к 0.25.

4.4 Сопоставление классического и нейросетевого подходов

Количественное сравнение трёх режимов на задаче об осцилляторе приведено в табл. 7 качественные различия систематизированы ранее в табл. 1. Классический РК4 превосходит PINN по точности прямой задачи на пять порядков при несопоставимо меньшей стоимости. Однако PINN решает обратную задачу в рамках единой оптимизации, тогда как для сеточных методов это потребовало бы отдельной внешней процедуры.

Метод	Основная метрика	Обратная задача	Стоимость
РК4 (прямая)	3.06×10^{-8}	нет	низкая
PINN (прямая)	2.33×10^{-3}	нет	высокая
PINN (обратная)	$ \hat{\delta} - \delta = 6.14 \times 10^{-3}$	да, $\hat{\delta} \approx 0.256$	высокая

Таблица 7. Сопоставление РК4 и PINN на задаче о затухающем осцилляторе (вариант 13). Для прямых задач указана максимальная ошибка решения; для обратной PINN — ошибка восстановленного параметра.

5 Обсуждение

Эксперименты согласуются с теорией во всех ключевых пунктах. Измеренные порядки сходимости $\hat{p} \approx 1.05, 2.03, 3.89$ воспроизводят теоретические $p = 1, 2, 4$; небольшое занижение для РК4 объясняется выходом на полку машинной точности на мелких сетках, где ошибка округления доминирует над ошибкой усечения. Это подчёркивает практический предел: дальнейшее дробление шага у методов высокого порядка не повышает точности, а лишь увеличивает стоимость и накопление round-off-ошибок.

Сравнение классики и PINN выявляет их взаимодополняющие ниши. Для прямых нежёстких задач классические методы Рунге–Кутты остаются золотым стандартом: они дают строгие априорные оценки погрешности, предсказуемый порядок и крайне низкую стоимость (РК4 достиг ошибки $\approx 10^{-8}$ на осцилляторе). PINN на тех же прямых задачах уступает в точности и стоимости и чувствительна к выбору гиперпараметров; для длинного временного горизонта потребовались инициализация по эталону и доводка L-BFGS. Вместе с тем PINN естественно решает обратную задачу, восстанавливая скрытый параметр δ из зашумлённых данных в рамках той же оптимизации, — именно здесь сетевой подход выигрывает у сеточных методов.

Ограничения работы. Рассмотрены только нежёсткие задачи, для которых явные методы безусловно применимы; для жёстких задач потребовались бы неявные A-устойчивые схемы. Оценка PINN получена для одной архитектуры, одного seed и одного набора гиперпараметров; кроме того, прямая задача использует warm-start по аналитическому решению, поэтому её не следует интерпретировать как полностью самостоятельное обучение без учителя. Тем не менее сделанные выводы об относительной точности, стоимости и применимости к обратным задачам носят устойчивый характер.

6 Заключение

В работе изложены и экспериментально проверены классические одношаговые методы численного решения задачи Коши — Эйлера, Хойна и Рунге–Кутты четвёртого порядка — на задачах варианта 13. Приведены вывод методов, таблицы Бутчера, теория локальной и глобальной погрешности и понятие абсолютной устойчивости с соответствующими областями в комплексной плоскости.

Вычислительный эксперимент на уравнении Бернулли $y' = -y/x - y^2$ подтвердил ожидаемую иерархию точности: при $n = 20$ максимальная абсолютная погрешность составила 6.4×10^{-2} для Эйлера, 3.0×10^{-3} для Хойна и 2.4×10^{-6} для РК4. Анализ порядка сходимости в логарифмических координатах дал наблюдаемые порядки $\hat{p} \approx 1.05, 2.03$ и 3.89 , что количественно подтверждает теоретические значения 1, 2 и 4.

В качестве моста к современным методам исследована физически-информированная нейронная сеть. На затухающем осцилляторе варианта 13 PINN решила прямую задачу с точностью 2.3×10^{-3} , а в обратной задаче восстановила коэффициент затухания $\hat{\delta} \approx 0.256$ при истинном $\delta = 0.25$ по зашумлённым данным. Прямое сопоставление показало, что классический РК4 предпочтителен для прямых нежёстких задач благодаря точности, дешевизне и строгим гарантиям, тогда как PINN ценна прежде всего в обратных задачах идентификации параметров.

Таким образом, классические и нейросетевые методы не конкурируют, а дополняют друг друга: первые образуют надёжное ядро для прямого интегрирования ОДУ, вторые расширяют арсенал на задачи, где требуется идентификация параметров или непрерывное дифференцируемое представление решения.

Приложение. Реализация одношаговых методов

```
def solve_euler(
    derivative: Callable[[float, float], float],
    x_values: NDArray[np.float64],
    y_start: float,
) -> NDArray[np.float64]:
    y_values: NDArray[np.float64] = np.zeros(len(x_values), dtype=np.float64)
    y_values[0] = y_start
    for index in range(len(x_values) - 1):
        step_size: float = x_values[index + 1] - x_values[index]
        y_values[index + 1] = y_values[index] + step_size * derivative(
            x_values[index], y_values[index]
        )
    return y_values

def solve_heun(
    derivative: Callable[[float, float], float],
    x_values: NDArray[np.float64],
    y_start: float,
) -> NDArray[np.float64]:
    y_values: NDArray[np.float64] = np.zeros(len(x_values), dtype=np.float64)
    y_values[0] = y_start
    for index in range(len(x_values) - 1):
        current_x: float = x_values[index]
        current_y: float = y_values[index]
        step_size: float = x_values[index + 1] - current_x
        slope_start: float = derivative(current_x, current_y)
        predicted_y: float = current_y + step_size * slope_start
        slope_end: float = derivative(x_values[index + 1], predicted_y)
        y_values[index + 1] = current_y + step_size * (slope_start + slope_end) / 2
    return y_values

def solve_runge_kutta_4(
    derivative: Callable[[float, float], float],
    x_values: NDArray[np.float64],
    y_start: float,
) -> NDArray[np.float64]:
    y_values: NDArray[np.float64] = np.zeros(len(x_values), dtype=np.float64)
    y_values[0] = y_start
    for index in range(len(x_values) - 1):
        current_x: float = x_values[index]
        current_y: float = y_values[index]
        step_size: float = x_values[index + 1] - current_x
        slope_1: float = derivative(current_x, current_y)
        slope_2: float = derivative(current_x + step_size / 2, current_y +
step_size * slope_1 / 2)
        slope_3: float = derivative(current_x + step_size / 2, current_y +
step_size * slope_2 / 2)
        slope_4: float = derivative(current_x + step_size, current_y + step_size *
slope_3)
        y_values[index + 1] = current_y + step_size * (
            slope_1 + 2 * slope_2 + 2 * slope_3 + slope_4
        ) / 6
    return y_values
```

Список литературы

- [1] E. Süli и D. F. Mayers, *An Introduction to Numerical Analysis*. Cambridge: Cambridge University Press, 2003.
- [2] MIT OpenCourseWare, «18.330 Introduction to Numerical Analysis». 2019 г.
- [3] M. Raissi, P. Perdikaris, и G. E. Karniadakis, «Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations», *Journal of Computational Physics*, т. 378, сс. 686–707, 2019.
- [4] E. Hairer, S. P. Nørsett, и G. Wanner, *Solving Ordinary Differential Equations I: Nonstiff Problems*, 2-е изд. Berlin: Springer, 1993.
- [5] Н. С. Бахвалов, Н. П. Жидков, и Г. М. Кобельков, *Численные методы*, 8-е изд. Москва: БИНОМ. Лаборатория знаний, 2011.
- [6] А. А. Самарский и А. В. Гулин, *Численные методы*. Москва: Наука, 1989.